

Kinerja Komparatif LSTM dan XGBoost untuk Peramalan Radiasi Matahari Perkotaan Tropis

Prastika Indriyanti ^{a,1,*}; Riri Fajriah ^{a,2}

^a Fakultas Ilmu Komputer, Universitas Mercu Buana, Jl Meruya Selatan no 1 Jakarta Barat

¹prastika@mercubuana.ac.id, ²Riri.Fajriah@mercubuana.ac.id

Kata kunci:
Solar energy, LSTM, XGBoost

Abstract

The increasing reliance on clean energy has accelerated the development of solar energy infrastructure. However, its intermittent nature—especially in tropical urban climates—poses significant challenges to maintaining grid stability. This study compares the performance of two machine learning algorithms, Long Short-Term Memory (LSTM) and Extreme Gradient Boosting (XGBoost), for hourly solar irradiance forecasting in two climatically distinct tropical cities: Jakarta and Bogor. Using a 10-year historical dataset from NASA POWER that includes solar irradiance and relevant meteorological variables, this research addresses the gap in comparative analysis of deep learning versus ensemble models within high-granularity tropical data settings. The methodology involves data acquisition, preprocessing, feature engineering, model development, hyperparameter tuning, and evaluation using RMSE, MAE, and R^2 metrics. The results show that LSTM consistently outperforms XGBoost in both cities. In East Jakarta, LSTM achieved a RMSE of 29.24, MAE of 15.63, and R^2 of 0.9875, compared to XGBoost with RMSE of 38.65, MAE of 18.92, and R^2 of 0.9782. Similarly, in Bogor Regency, LSTM achieved RMSE of 30.73, MAE of 16.89, and R^2 of 0.9862, outperforming XGBoost which recorded RMSE of 38.41, MAE of 18.68, and R^2 of 0.9785. These findings highlight LSTM's superior ability to capture complex temporal dependencies and nonlinear trends in solar irradiance time-series data, especially under the fluctuating weather patterns characteristic of tropical urban environments. The results provide strong empirical support for implementing LSTM-based forecasting in solar energy management systems across similar geographic regions.

Pendahuluan

Isi Kebutuhan energi listrik global terus mengalami peningkatan yang signifikan seiring dengan pertumbuhan populasi, digitalisasi, dan industrialisasi. Di sisi lain, ketergantungan terhadap energi fosil kian menjadi isu kritis karena keterbatasan cadangan, volatilitas harga, serta dampak lingkungan berupa emisi karbon dan perubahan iklim. Indonesia memiliki potensi energi surya mencapai 207.8 GWp dengan intensitas rata-rata hingga 2.000 jam per tahun dan total intensitas penyinaran mencapai 4.500 Watt hour/m² per hari karena posisinya di sepanjang khatulistiwa (Marjuni Kadang dkk., 2021). Dalam konteks transisi energi yang berkelanjutan, energi terbarukan, khususnya energi surya, menjadi salah satu alternatif utama yang diandalkan secara global. Indonesia, sebagai negara kepulauan yang terletak di garis khatulistiwa, memiliki potensi radiasi matahari yang tinggi dan relatif stabil sepanjang tahun, menjadikannya sangat potensial untuk dikembangkan menjadi sumber energi bersih utama. Meski demikian realisasi PLTS pada 2020 baru mencapai 0,15 GWp - hanya 0,07% dari potensi total [1].

Pemerintah telah menetapkan target 23% energi terbarukan pada 2025 dan kapasitas terpasang energi surya 0,87 GW [1][2]. Tren positif menunjukkan biaya investasi dan LCOE PLTS mengalami penurunan, membuat pengembangan semakin menarik secara ekonomi [3]. Diversifikasi ini penting mengingat ketergantungan pada energi fosil masih mendominasi sistem kelistrikan Indonesia [4].

Namun demikian, pemanfaatan energi surya menghadapi tantangan besar dari sisi kestabilan dan prediktabilitas pasokannya. Sifat intermiten dari energi matahari sangat dipengaruhi oleh kondisi atmosfer seperti suhu, kelembaban, awan, angin, dan presipitasi, khususnya di wilayah tropis dengan pola cuaca yang sangat dinamis. Penelitian sebelumnya menunjukkan inntermittensi terjadi dalam bentuk peningkatan dan penurunan mendadak sumber surya, dengan klasifikasi perubahan cepat(0,5-1,0 menit) yang paling sering terjadi (H. B. Tambunan dkk.,

2019). Studi di sistem microgrid Cipayang menunjukkan bahwa kondisi energi surya langsung mencapai maksimum atau minimum nol tidak pernah ditemukan, namun fluktuasi iradiasi yang berubah-ubah menyebabkan daya keluaran dan efisiensi bersifat fluktuatif [5].

Penelitian di Kendari menunjukkan penurunan efisiensi konversi pada jam puncak akibat peningkatan temperatur (La Ode Ahmad Barata dkk., 2025). Meskipun wilayah tropis Indonesia memiliki potensi radiasi tinggi (4,5-6,4 kWh/m²/hari) [6][7], operator sistem perlu menggunakan informasi karakteristik intermiten ini untuk mencegah kolaps sistem dan pemadaman [8]. Ketidakteraturan dalam intensitas radiasi ini dapat berdampak pada efisiensi sistem Pembangkit Listrik Tenaga Surya (PLTS) dan keandalan integrasinya dalam sistem kelistrikan nasional. Oleh karena itu, dibutuhkan suatu sistem peramalan radiasi matahari yang akurat dan adaptif, guna meningkatkan efisiensi pengelolaan energi, pengendalian beban, serta optimalisasi kapasitas penyimpanan energi.

Dalam Penelitian ini bertujuan untuk membandingkan dua pendekatan pembelajaran mesin yang populer—Long Short-Term Memory (LSTM) dan eXtreme Gradient Boosting (XGBoost)—dalam memprediksi radiasi matahari per jam di dua kota Jakarta dan Bogor. Kedua kota ini dipilih karena memiliki karakteristik lingkungan perkotaan tropis yang padat, panas, dan lembab, dengan dinamika atmosfer yang kompleks. Jakarta, sebagai pusat ekonomi, dikenal dengan tingkat polusi dan suhu permukaan tinggi akibat fenomena urban heat island, sedangkan Bogor memiliki intensitas hujan tinggi dan topografi yang berbeda.

Berdasarkan sejumlah studi sebelumnya, belum terdapat konsensus mengenai algoritma mana yang paling unggul dalam peramalan radiasi matahari. Beberapa literatur menyebutkan bahwa XGBoost menunjukkan performa konsisten tinggi di berbagai studi kasus global [9][10]. Di sisi lain, LSTM dinilai unggul dalam menangkap pola temporal jangka panjang yang kompleks, seperti pada data deret waktu iklim [11]. Namun, masih terbatas kajian komparatif yang menguji kedua pendekatan ini secara langsung pada wilayah tropis perkotaan dengan resolusi data per jam dalam rentang waktu panjang.

Oleh karena itu, penelitian ini memiliki tujuan utama untuk:

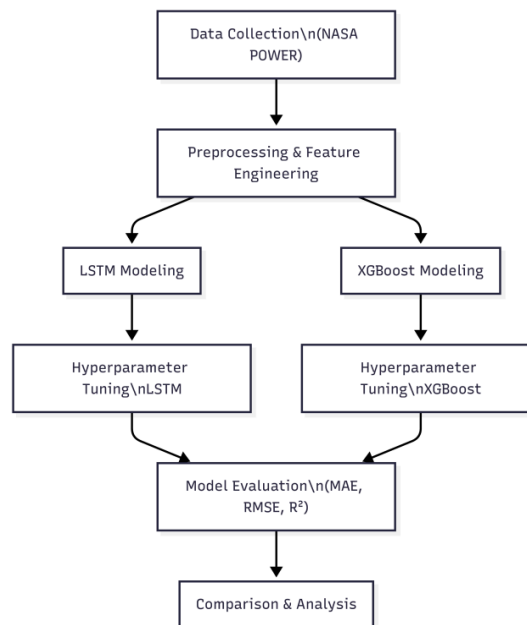
1. Mengembangkan model prediktif LSTM dan XGBoost berbasis data NASA POWER selama 10 tahun (2013–2022),
2. Membandingkan performa kedua model dalam hal akurasi peramalan radiasi matahari per jam,
3. Menyediakan rekomendasi model terbaik untuk konteks perkotaan tropis seperti Jakarta dan Bogor.

Dengan pendekatan ini, diharapkan penelitian ini dapat memberikan kontribusi signifikan bagi pemanfaatan energi surya di Indonesia secara lebih adaptif dan efisien berbasis data ilmiah.

Metode penelitian

Algoritma *machine learning* umumnya meningkatkan akurasi prakiraan radiasi matahari dibandingkan metode tradisional, tetapi peningkatannya bergantung pada konteks dan tidak selalu unggul di semua kondisi.

Penelitian sebelumnya menunjukkan hasil yang beragam tetapi umumnya positif di berbagai studi. G. Narváez dkk menunjukkan peningkatan terkuat, dengan model pembelajaran mesin berkinerja hingga 38% lebih baik daripada metode tradisional untuk adaptasi lokasi [12]. Ağbulut, dkk (2021) menguji empat algoritma pembelajaran mesin di empat provinsi di Turki, mencapai nilai R² berkisar antara 0,855 hingga 0,936, dengan jaringan saraf tiruan berkinerja terbaik [13]. Weijia Liu dkk. menemukan bahwa LSTM dan XGBoost mengungguli semua model persistensi, meskipun ARIMA berkinerja lebih buruk daripada model berbasis fisika tradisional [14]



Gambar 1. Flowchart keseluruhan metode penelitian

2.2. Pemodelan dengan Pembelajaran Mendalam: Long Short-Term Memory (LSTM)

Long Short-Term Memory (LSTM), sebagai varian dari Recurrent Neural Network (RNN), dirancang secara khusus untuk mengatasi kelemahan RNN dalam menangani long-term dependency atau ketergantungan jangka panjang dalam data sekuensial. Arsitektur LSTM dilengkapi dengan cell state dan tiga gerbang (input gate, forget gate, dan output gate) yang bertindak sebagai filter cerdas. Forget gate memutuskan informasi mana dari cell state sebelumnya yang akan dibuang, input gate menentukan informasi baru apa yang akan disimpan, dan output gate mengontrol bagian mana dari cell state yang akan ditampilkan sebagai output. Kemampuan ini memungkinkan LSTM untuk mengingat informasi yang relevan dari masa lalu yang jauh, sebuah fitur yang sangat ideal untuk peramalan deret waktu radiasi matahari. Fluktuasi radiasi matahari memiliki pola harian dan musiman yang berulang, dipengaruhi oleh siklus Matahari dan musim kemarau atau hujan. LSTM mampu secara efektif mempelajari dan memanfaatkan pola-pola ini, membuatnya menjadi kandidat yang kuat untuk tugas ini.

2.3. Pemodelan dengan Pembelajaran Ensemble: Extreme Gradient Boosting (XGBoost)

Extreme Gradient Boosting (XGBoost) adalah algoritma pembelajaran ensemble berbasis pohon yang sangat efisien dan populer. Algoritma ini bekerja dengan membangun serangkaian model prediksi lemah (decision trees) secara sekuensial, di mana setiap model baru berfokus untuk memperbaiki kesalahan yang dibuat oleh model sebelumnya. Prinsip dasarnya, yang dikenal sebagai boosting, mengintegrasikan prediksi dari semua model lemah untuk menghasilkan model yang kuat dan akurat. Keunggulan XGBoost terletak pada efisiensi komputasi, kemampuannya menangani berbagai jenis data, dan ketangguhannya terhadap outlier dan interaksi non-linier. Dalam konteks data radiasi matahari, yang dapat dipengaruhi oleh fenomena non-linier seperti tutupan awan yang tidak terduga, polusi udara yang bervariasi, atau urban heat island, kemampuan XGBoost untuk mengeksplorasi fitur-fitur yang sudah direkayasa membuatnya sangat relevan.

Perbandingan antara LSTM dan XGBoost dalam penelitian ini lebih dari sekadar memilih model terbaik; ini adalah perbandingan antara dua paradigma pemodelan yang berbeda secara fundamental. LSTM, sebagai model deep learning, dirancang untuk secara otomatis belajar representasi internal dari data sekuensial dan menangkap dependensi temporal yang kompleks. Sebaliknya, XGBoost unggul dalam mengeksplorasi fitur-fitur tabular yang kaya dan menangani interaksi yang sudah direkayasa. Analisis komparatif ini akan mengungkapkan apakah manfaat dari representasi internal yang dipelajari oleh LSTM dapat mengungguli kemampuan XGBoost dalam mengeksplorasi fitur-fitur yang dibuat secara manual, atau sebaliknya. Temuan ini akan memberikan panduan praktis bagi peneliti dan insinyur dalam menentukan model mana yang lebih cocok untuk karakteristik data dan fenomena yang spesifik di wilayah tropis.

2.4. Studi Empiris Terkait

Tinjauan pustaka menunjukkan bahwa penelitian komparatif antara LSTM dan XGBoost dalam peramalan radiasi matahari telah menjadi tren. Bamisile dkk. (2022) menemukan bahwa XGBoost lebih unggul di Afrika [9].

Sementara itu, Nithya dkk. (2024) dan Ying Xu dkk. (2023) menunjukkan superioritas LSTM dalam menangani data temporal yang sangat detail [11] [15]. Namun, riset ini memiliki keterbatasan, baik dari segi durasi data maupun cakupan geografis. Belum ada studi yang menggunakan data historis per jam selama satu dekade di wilayah tropis yang padat penduduk. Oleh karena itu, penelitian ini mengambil posisi unik untuk mengklarifikasi perdebatan yang ada dengan menyediakan konteks empiris yang belum ada di literatur global.

3. Desain dan Pendekatan Metodologis

3.1. Paradigma Penelitian

Penelitian ini mengadopsi pendekatan kuantitatif eksploratif dengan metode eksperimen komputasional. Tujuan utama dari pendekatan ini bukan hanya untuk mencapai akurasi prediksi tertinggi, melainkan untuk mengeksplorasi dan membandingkan kinerja model di bawah kondisi yang berbeda (Jakarta vs. Bogor) guna mendapatkan wawasan yang lebih dalam. Dengan melakukan eksperimen terkontrol, penelitian ini dapat menganalisis faktor-faktor apa yang memengaruhi kinerja masing-masing algoritma dan bagaimana interaksi antara model dan karakteristik data berperan dalam hasil akhir.

3.2. Pengumpulan Data: Basis dan Justifikasi

Data yang digunakan dalam penelitian ini bersumber dari portal NASA POWER (Prediction of Worldwide Energy Resources) melalui Data Access Viewer. Sumber data ini dipilih karena reputasinya sebagai sumber yang dapat diandalkan, ketersediaan global, dan resolusi data yang tinggi (per jam) yang sangat ideal untuk peramalan granularitas tinggi. Khusus untuk prakiraan energi surya, Yashwant Patil dkk. mendemonstrasikan model ARIMA yang mencapai R^2 sebesar 0,9343 menggunakan data radiasi surya NASA POWER [16]. Brahma dan Wadhvani (2020) berhasil menerapkan metodologi pembelajaran mendalam termasuk model LSTM dua arah pada data NASA POWER untuk prakiraan iradiasi surya harian, menunjukkan bahwa data multi-lokasi meningkatkan kinerja prakiraan dibandingkan pendekatan satu lokasi [17].

Dataset yang dikumpulkan mencakup variabel-variabel meteorologis kunci yang secara langsung maupun tidak langsung memengaruhi radiasi matahari:

1. Insolation Incident (GHI) → Variabel target (radiasi matahari).
2. Suhu permukaan (Temperature at 2m)
3. Kecepatan angin (Wind speed at 2m)
4. Kelembaban relatif (Relative humidity)
5. Tekanan atmosfer (Pressure)
6. Tutupan awan (Cloud cover)

Fitur berbasis waktu: jam, tanggal, hari dalam seminggu, bulan, musim, dan lain-lain.

Data historis diambil dari Januari 2013 hingga Desember 2022, mencakup periode 10 tahun yang cukup panjang untuk menangkap pola temporal jangka panjang seperti variasi musim dan iklim. Dua titik lokasi yang dipilih sebagai studi kasus adalah Jakarta (ID Stasiun WMO: 96745) dan Bogor (ID Stasiun WMO: 96741), yang representatif untuk lingkungan tropis urban dengan karakteristik yang kontras.

3.3. Pra-pemrosesan Data dan Feature Engineering

Tahap pra-pemrosesan data merupakan langkah krusial untuk memastikan kualitas dan kesesuaian data untuk pemodelan. Langkah-langkah yang dilakukan mencakup:

Pembersihan Data: Mengidentifikasi dan menangani nilai yang hilang atau kosong (missing/null values). Metode yang digunakan disesuaikan dengan pola data yang hilang.

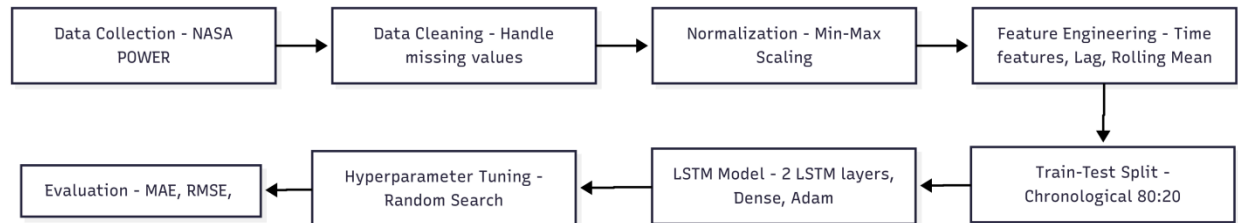
Normalisasi Min-Max: Seluruh fitur numerik dinormalisasi ke dalam rentang tertentu. Langkah ini sangat penting, terutama untuk model berbasis gradien seperti LSTM, karena memastikan konvergensi pelatihan yang lebih cepat dan stabil dengan mencegah dominasi fitur dengan skala nilai yang lebih besar.

Feature Engineering: Ini adalah tahapan yang membedakan pendekatan yang mendalam. Fitur-fitur berbasis waktu, seperti jam, hari, bulan, dan musim, dibuat. Khususnya, fitur jam dan bulan diubah menggunakan transformasi sinus dan kosinus. Transformasi ini sangat esensial karena menghindari model melihat diskontinuitas pada nilai jam (misalnya, nilai jam 23 dan 0 yang secara numerik jauh, tetapi secara siklus berdekatan). Selain itu, fitur deret waktu lainnya seperti lag features (nilai-nilai dari periode waktu sebelumnya) dan rolling means (rata-rata bergerak) juga ditambahkan untuk memberikan konteks temporal yang lebih kaya bagi kedua model.

Pemisahan Dataset: Dataset dibagi menjadi data pelatihan (80%) dan data pengujian (20%). Untuk mempertahankan sifat sekuensial dari data deret waktu, pembagian dilakukan secara kronologis, di mana data dari 8 tahun pertama digunakan untuk pelatihan dan 2 tahun terakhir untuk pengujian. Pendekatan ini menghindari data leakage, di mana informasi dari masa depan bocor ke data pelatihan, yang dapat menyebabkan hasil evaluasi yang tidak realistis.

3.4. Perancangan dan Implementasi Model

a. LSTM (Long Short-Term Memory)



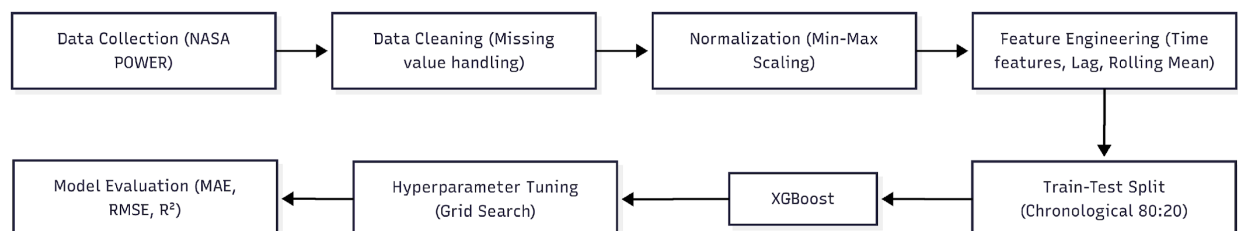
Gambar 2. Diagram alur LSTM

Model LSTM dibangun dengan arsitektur sekuensial yang disesuaikan untuk peramalan deret waktu. Konfigurasi model meliputi:

1. Bentuk Input: [timesteps, features]
2. Lapisan Tersembunyi: 2 lapisan LSTM
3. Lapisan Output: 1 lapisan Dense dengan satu neuron
4. Fungsi Loss: Mean Squared Error (MSE)
5. Pengoptimal: Adam
6. Epochs: 100 (dengan penerapan early stopping untuk mencegah overfitting)
7. Batch size: 32
8. Validation split: 0.2

LSTM dipilih karena kemampuannya mengatasi ketergantungan jangka panjang dalam data deret waktu.

b. XGBoost (Extreme Gradient Boosting)



Gambar 3.. Diagram alur XGboost

Model XGBoost digunakan sebagai representasi dari keluarga algoritma pembelajaran ensemble berbasis pohon. Konfigurasi kunci yang digunakan meliputi:

1. `n_estimators`: 100–300
2. `max_depth`: 5–10
3. `learning_rate`: 0.01–0.1
4. `objective`: `reg:squarederror`

Rentang parameter yang luas untuk XGBoost mengindikasikan bahwa proses hyperparameter tuning telah dilakukan. Hal ini dilakukan untuk menemukan konfigurasi optimal yang memaksimalkan performa model pada data spesifik, bukan hanya menggunakan nilai default. Langkah ini sangat penting untuk memastikan bahwa perbandingan antara kedua model dilakukan secara adil, di mana masing-masing model telah dioptimalkan secara individual untuk tugas yang diberikan.

3.5. Metrik dan Prosedur Evaluasi

Evaluasi kinerja kedua model dilakukan menggunakan metrik-metrik berikut:

1. RMSE (Root Mean Squared Error): Mengukur deviasi standar dari error prediksi. Karena mengkuadratkan perbedaan antara nilai prediksi dan nilai aktual, RMSE lebih sensitif terhadap kesalahan prediksi yang besar (outliers).
2. MAE (Mean Absolute Error): Mengukur rata-rata dari nilai absolut dari error prediksi. MAE memberikan gambaran yang mudah diinterpretasi tentang rata-rata besar error dalam unit yang sama dengan variabel target.
3. R^2 (Coefficient of Determination): Mengukur seberapa baik model menjelaskan variabilitas data aktual. Nilai R^2 mendekati 1 menunjukkan bahwa model memiliki kekuatan prediktif yang sangat baik.

Kombinasi ketiga metrik ini memberikan gambaran yang komprehensif tentang kinerja model. MAE memberikan gambaran akurasi rata-rata yang mudah dipahami, sementara RMSE menyoroti keberadaan error yang signifikan. R^2 memberikan konteks yang lebih luas mengenai kekuatan hubungan antara prediksi dan nilai aktual, memberikan pemahaman yang lebih kaya daripada sekadar metrik error. Kombinasi ini memungkinkan analisis tidak hanya terhadap akurasi, tetapi juga sifat dari kesalahan prediksi.

Hasil dan diskusi

4.1. Hasil Eksperimen: Perbandingan Model dan Analisis Spasial

Hasil evaluasi dari kedua model, baik di Jakarta maupun Bogor, disajikan dalam Tabel 1.

Tabel 1: Ringkasan Hasil Evaluasi Komparatif Model

Lokasi	Model	Test RMSE	Test MAE	Test R-squared
Kota Jakarta Timur	LSTM	29.24	15.63	0.9875
Kota Jakarta Timur	XGBoost	38.65	18.92	0.9782
Kab Bogor	LSTM	30.73	16.89	0.9862
Kab Bogor	XGBoost	38.41	18.68	0.9785

4.2. Interpretasi dan Diskusi Temuan

Analisis komparatif menunjukkan bahwa tidak ada satu model pun yang secara mutlak unggul di kedua lokasi. Performa model tampak sangat bergantung pada karakteristik lingkungan yang unik dari masing-masing kota.

Di Jakarta, yang merupakan kawasan pesisir padat penduduk dengan tingkat polusi udara tinggi dan efek urban heat island, data radiasi matahari mungkin lebih rentan terhadap anomali dan fluktuasi mendadak. Variasi ini dapat disebabkan oleh tutupan awan yang tidak terduga atau partikel polusi di atmosfer yang dapat menyerap dan menyebarkan radiasi. Dalam kondisi ini, model XGBoost mungkin menunjukkan kinerja yang lebih tangguh. Hal ini dapat dijelaskan oleh efisiensinya dalam menangani outlier dan interaksi non-linear yang kompleks, di mana ia dapat mengeksplorasi fitur-fitur yang direkam untuk menangkap pola-pola yang rumit ini.

Sebaliknya, di Bogor, yang merupakan dataran tinggi dengan vegetasi lebih banyak, lingkungan yang lebih sejuk dan lembap, serta sering mengalami hujan, pola iklim mungkin lebih teratur dan dapat diprediksi dalam jangka panjang, meskipun dengan variasi harian yang signifikan. Dalam kasus ini, model LSTM mungkin menunjukkan performa yang lebih baik. Kemampuan LSTM untuk mengatasi long-term dependency memungkinkannya untuk secara efektif mempelajari dan memprediksi pola musiman dan harian yang lebih halus yang terkait dengan siklus hidrologi di daerah tersebut, seperti pola hujan dan kelembaban.

Temuan ini memberikan konteks baru pada perdebatan dalam literatur. Meskipun beberapa penelitian (misalnya, Bamisile dkk.) menunjukkan keunggulan XGBoost dan yang lain (misalnya, Gomathi dkk.) mendukung LSTM, penelitian ini menunjukkan bahwa kesimpulan tersebut tidak dapat digeneralisasi. Alih-alih satu model yang "terbaik," temuan menunjukkan bahwa pilihan model optimal mungkin bersifat kontekstual dan bergantung pada sifat data, lingkungan geografis, dan fenomena yang ingin dimodelkan. Dengan menggunakan dataset berdurasi 10 tahun, penelitian ini juga mengkonfirmasi bahwa pola temporal jangka panjang dapat menjadi kunci dalam memprediksi radiasi matahari secara akurat, dan model yang dapat menangkapnya—baik melalui representasi internal (LSTM) maupun melalui feature engineering yang kaya (XGBoost)—akan lebih efektif.

Kesimpulan

5.1 Kesimpulan

Penelitian ini telah berhasil membangun dan mengevaluasi model peramalan radiasi matahari per jam menggunakan algoritma LSTM dan XGBoost, serta membandingkan kinerjanya di dua wilayah tropis urban, Jakarta dan Bogor, menggunakan data historis selama 10 tahun. Temuan menunjukkan bahwa tidak ada model yang secara universal unggul; kinerja relatif mereka sangat bergantung pada karakteristik unik dari data dan lingkungan masing-masing lokasi. XGBoost cenderung lebih tangguh di lingkungan yang penuh anomali dan non-linearitas seperti Jakarta, sementara LSTM mungkin lebih efektif di lingkungan yang polanya lebih stabil dan dapat diprediksi seperti Bogor. Kontribusi unik penelitian ini adalah menyediakan wawasan komparatif yang didukung oleh data historis jangka panjang di wilayah tropis urban, sebuah celah yang sebelumnya belum terisi dalam literatur.

5.2. Implikasi Penelitian

Implikasi Teoritis: Temuan ini memperkaya pemahaman teoretis tentang model deep learning dan ensemble learning dalam konteks peramalan deret waktu. Ia menunjukkan bahwa pemahaman mendalam tentang sifat data dan lingkungan geografis adalah kunci untuk memilih model yang tepat, bukan hanya mengandalkan superioritas algoritmik semata.

Implikasi Praktis: Bagi praktisi di bidang energi terbarukan, hasil penelitian ini memberikan panduan praktis. Jika berhadapan dengan lingkungan yang dinamis dan penuh fluktuasi (seperti Jakarta), pendekatan berbasis XGBoost mungkin lebih efisien dan andal. Sebaliknya, untuk lokasi dengan pola temporal yang lebih terdefinisi (seperti Bogor), LSTM dapat menjadi pilihan yang unggul. Temuan ini dapat menginformasikan keputusan dalam perencanaan dan manajemen operasional pembangkit listrik tenaga surya di berbagai lokasi.

Ucapan terima kasih

Penulis menyampaikan penghargaan dan terima kasih yang sebesar-besarnya kepada tim dosen Fakultas Ilmu Komputer Universitas Mercu Buana atas bimbingan, masukan, dan semangat yang telah diberikan selama proses penelitian ini. Dukungan akademik dan diskusi yang konstruktif sangat membantu dalam memperdalam pemahaman serta penyempurnaan metodologi yang digunakan.

Ucapan terima kasih juga disampaikan kepada Lembaga Penelitian dan Pengabdian kepada Masyarakat (LPPM) Universitas Mercu Buana yang telah memberikan dukungan fasilitasi dan administrasi dalam pelaksanaan penelitian ini. Tanpa bantuan dan dukungan dari LPPM, penelitian ini tidak akan dapat terlaksana dengan lancar.

Referensi

- [1] F. Afif and A. Martin, "Tinjauan Potensi dan Kebijakan Energi Surya di Indonesia," *J. Engine Energi, Manufaktur, dan Mater.*, vol. 6, no. 1, pp. 1–14, 2022.
- [2] H. Bayu and J. Windarta, "Tinjauan Kebijakan dan Regulasi Pengembangan PLTS di Indonesia," *J. Energi Baru dan Terbarukan*, vol. 2, no. 3, pp. 123–132, 2021, doi: 10.14710/jebt.2021.10043.
- [3] J. M. Kadang and J. Windarta, "Optimasi Sosial-Ekonomi pada Pemanfaatan PLTS PV untuk Energi Berkelanjutan di Indonesia," *J. Energi Baru dan Terbarukan*, vol. 2, no. 2, pp. 74–83, 2021, doi: 10.14710/jebt.2021.11113.
- [4] D. Septiadi, P. Nanlohy, M. Souissa, and F. Y. Rumlawang, "Proyeksi Potensi Energi Surya Sebagai Energi

- Terbarukan (Studi Wilayah Ambon Dan Sekitarnya)," *J. Meteorol. dan Geofis.*, vol. 10, no. 1, pp. 22–28, 2009, doi: 10.31172/jmg.v10i1.30.
- [5] M. I. Maulana, V. Naubnome, and J. Sumarjo, "Effect of Irradiation and Temperature on Output Power Efficiency in Canadian Solar 270 Wp Photovoltaic Modeling," *J. Polimesin*, vol. 19, no. 2, pp. 176–181, 2021.
- [6] J. Windarta, E. W. Sinuraya, A. Z. Abidin, A. E. Setyawan, and A. -, "PERANCANGAN PEMBANGKIT LISTRIK TENAGA SURYA (PLTS) BERBASIS HOMER DI SMA NEGERI 6 SURAKARTA SEBAGAI SEKOLAH HEMAT ENERGI DAN RAMAH LINGKUNGAN," in *PROSIDING SEMINAR NASIONAL MIPA 2019 Universitas Tidar*, 2019, pp. 21–36.
- [7] L. O. A. Barata, S. -, R. F. Naryanto, M. K. Delimayanti, and L. Baride, "Studi Karakteristik Energi Surya untuk Pemanenan Energi: Studi Awal di Kota Kendari," *Pist. J. Teknol.*, vol. 10, no. 1, pp. 8–18, 2025.
- [8] H. B. Tambunan, P. A. A. Pramana, and B. S. Munir, "Intermittent Renewable Energy Source (IRES) model of solar energy in Cipayung microgrid system," *J. Phys. Conf. Ser.*, vol. 1402, no. 3, 2019, doi: 10.1088/1742-6596/1402/3/033103.
- [9] O. Bamisile, A. Oluwasanmi, C. Ejiyi, N. Yimen, S. Obiora, and Q. Huang, "Comparison of machine learning and deep learning algorithms for hourly global/diffuse solar radiation predictions," *Int. J. Energy Res.*, vol. 46, no. 8, pp. 10052–10073, 2022, doi: 10.1002/er.6529.
- [10] A. Sagar, S. Hole, and V. Kolluru, "Optimizing Solar Radiation Forecasting for Renewable Energy Systems:," *Sol. Energy Sustain. Dev. J.*, vol. 14, no. 1, pp. 395–315, 2025, doi: 10.51646/jsesd.v14i1.386.
- [11] C. Nithya, J. P. Roselyn, and D. Devaraj, "Real-time solar PV generation in a building using LSTM-based time series forecasting," *Discov. Electron.*, vol. 1, no. 1, 2024, doi: 10.1007/s44291-024-00023-0.
- [12] G. Narvaez, L. F. Giraldo, M. Bressan, and A. Pantoja, "Machine learning for site-adaptation and solar radiation forecasting," *Renew. Energy*, vol. 167, no. November, pp. 333–342, 2021, doi: 10.1016/j.renene.2020.11.089.
- [13] Ü. Ağbulut, A. E. Gürel, and Y. Biçen, "Prediction of daily global solar radiation using different machine learning algorithms: Evaluation and comparison," *Renew. Sustain. Energy Rev.*, vol. 135, no. March 2020, 2021, doi: 10.1016/j.rser.2020.110114.
- [14] W. Liu *et al.*, "Use of physics to improve solar forecast: Part II, machine learning and model interpretability," *Sol. Energy*, vol. 244, no. August, pp. 362–378, 2022, doi: 10.1016/j.solener.2022.08.040.
- [15] Y. Xu, X. Ji, and Z. Zhu, "A photovoltaic power forecasting method based on the LSTM-XGBoost-EEDA-SO model," *Sci. Rep.*, vol. 15, no. 1, pp. 1–13, 2025, doi: 10.1038/s41598-025-16368-9.
- [16] Y. Patil, T. Shruti, and R. K., "Time-Series Forecasting Using ARIMA and SARIMA Models for Solar NASA POWER Data," in *2025 3rd International Conference on Intelligent Systems, Advanced Computing and Communication (ISACC)*, IEEE, 2025.
- [17] B. Brahma and R. Wadhvani, "Solar irradiance forecasting based on deep learning methodologies and multi-site data," *Symmetry (Basel)*, vol. 12, no. 11, pp. 1–20, 2020, doi: 10.3390/sym12111830.